




Travaux Pratiques - Analyse de Données

Option : Systèmes Informatiques

Analyse des Correspondances Multiples (ACM) sur le Marché des Transferts de Football Européen

Réalisé par :

HIMEUR Idris

DIAR Adem Abdelhafidh

Encadré par :

Mme. BESSAH Naima (ESI)

31 Décembre 2025

Promotion : 2025/2026

Résumé

Cette étude applique l'Analyse des Correspondances Multiples (ACM) à un ensemble de 17 962 acquisitions de joueurs sur le marché européen des transferts. L'objectif est d'identifier les associations entre variables qualitatives (position, région, âge, ligue, etc.) et de révéler des profils-types d'acquisitions.

Le jeu de données comprend 13 variables décrivant différents aspects du marché des transferts européens, dont 6 variables actives utilisées pour l'ACM : la ligue, la fenêtre de transfert, la position du joueur, la région géographique, le groupe d'âge et le statut de transfert gratuit.

L'analyse révèle que les 5 premiers axes factoriels expliquent 98,48% de l'inertie totale après correction de Benzécri. Le premier axe (57,04%) oppose les transferts gratuits et les joueurs âgés aux acquisitions payantes et joueurs jeunes respectivement, tandis que le deuxième axe (25,67%) distingue les profils de joueurs selon leur maturité et leur région d'origine. Les axes suivants caractérisent les spécificités des différentes ligues européennes et les stratégies de recrutement.

Les résultats mettent en évidence des axes factoriels structurant le marché et permettent une projection de variables supplémentaires quantitatives et qualitatives, offrant une compréhension approfondie des dynamiques du marché des transferts de football européen.

Mots-clés : Analyse des Correspondances Multiples, Transferts de Football, Marché Européen, Variables Qualitatives, Axes Factoriels, Profils de Joueurs

Table des matières

1	Présentation des données & méthode	1
1.1	Description du jeu de données	1
1.2	Prétraitement des données	1
1.2.1	Gestion des valeurs manquantes	1
1.2.2	Regroupement de modalités	1
1.2.3	Classification préalable : clustering K-Means	1
2	Application de l'Analyse des Correspondances Multiples	2
2.1	Définition du modèle	2
2.2	Valeurs propres et inertie expliquée	2
2.2.1	Tableau des valeurs propres	2
2.2.2	Comparaison avant/après correction de Benzécri	2
2.2.3	Visualisation de l'éboulis des valeurs propres	3
2.2.4	Inertie cumulée	3
2.3	Choix des axes retenus	4
2.4	Projection des individus	4
2.5	Contributions et qualité de représentation des modalités	4
2.5.1	Projection des modalités actives	4
2.5.2	Contributions des modalités par axe	5
2.5.3	Qualité de représentation ($\cos^2$) des modalités	6
2.5.4	Contributions des variables	6
2.6	Dénomination des axes	7
2.7	Synthèse des regroupements de modalités	7
3	Projection de variables supplémentaires	7
3.1	Méthode de projection	7
3.2	Projection de la valeur marchande et des catégories de prix	8
3.2.1	Variable quantitative : <code>market_val_amnt</code>	8
3.2.2	Variable qualitative : <code>transfer_fee_group</code>	8
3.3	Analyse ciblée : comportement des transferts non gratuits	8
4	Projection de la variable <code>cluster</code> (Classification K-Means)	9
4.1	Projection des clusters sur le plan factoriel	9
4.1.1	Caractérisation des clusters	9
4.2	Pertinence de la classification	10
5	Synthèse & perspectives	10
5.1	Principaux profils identifiés	10
5.2	Contributions méthodologiques	10
5.3	Limites et perspectives	10
5.3.1	Limites	10
5.3.2	Perspectives	11
5.4	Recommandations analytiques	11
A	Comparaison méthodologique (ACM / ACP / FAMD)	12
A.1	Analyse en Composantes Principales (ACP)	12
A.2	Analyse Factorielle de Données Mixtes (FAMD)	12
A.3	Analyse des Correspondances Multiples (ACM)	12
B	Preprocessing détaillé	12
B.1	Imputation des valeurs manquantes	12
B.2	Regroupement des modalités rares	13
B.3	Clustering K-Means des équipes	13
C	Pipeline détaillé de prétraitement des données	13
D	Tableaux statistiques complets	18
D.1	Contributions détaillées des modalités	18

D.2	Qualité de représentation moyenne par variable	18
-----	--	----

1 Présentation des données & méthode

1.1 Description du jeu de données

Le jeu de données utilisé dans cette étude, obtenu après un processus de pré-traitement, comprend **17,962 observations** représentant des acquisitions de joueurs, ainsi que **13 variables** décrivant différents aspects du marché des transferts européens.

Lien du jeu de données après pré-traitement : jeu de données après pré-traitement

Variables qualitatives :

- **league** : Ligue européenne (7 modalités : IT1, PO1, FR1, NL1, GB1, ES1, L1)
- **season** : Saison (13 modalités : 2009-2022)
- **window** : Fenêtre de transfert (2 modalités : été(W), hiver(S))
- **player_pos_grouped** : Position du joueur (4 modalités : Défenseur, Attaquant, Milieu, Gardien)
- **player_region** : Région d'origine (5 modalités : Europe Ouest, Amérique Sud, Afrique, Europe Est, Autre)
- **age_group** : Groupe d'âge (4 modalités : Young ≤ 21 , Prime 22-25, Experienced 26-29, Veteran 30+)
- **is_free** : Transfert gratuit (2 modalités : True, False)
- **transfer_fee_group** : Catégorie de prix (4 modalités : Free, Cheap 0-2M, Medium 2-7M, Expensive 7M+)
- **team_name** : Nom de l'équipe (nombreuses modalités)
- **player_nation** : Nationalité du joueur (153 modalités)
- **cluster** : Cluster d'équipe (10 modalités, résultat K-Means)

Variables quantitatives :

- **market_val_amnt** : Valeur marchande du joueur (moyenne : 3,8M€, médiane : 800k€)
- **transfer_fee_amnt** : Montant du transfert (moyenne : 3,9M€)

1.2 Prétraitement des données

Lien du jeu de données avant Prétraitement : jeu de données avant Prétraitement.

1.2.1 Gestion des valeurs manquantes

Les données ont fait l'objet d'un prétraitement minutieux, incluant l'imputation des valeurs manquantes, réalisée à l'aide d'un modèle d'apprentissage automatique pour les variables quantitatives `transfer_fee_amnt` et `market_value_amnt`. Les détails complets de ces étapes de prétraitement sont présentés en annexe B.

1.2.2 Regroupement de modalités

Dans le cadre de l'ACM, et afin d'assurer une représentation stable des variables tout en limitant la dispersion liée aux modalités rares ainsi qu'au nombre élevé de catégories par variable, plusieurs regroupements ont été effectués :

- **Position** : Regroupement des positions détaillées en 4 catégories principales
- **Âge** : Création de 4 groupes d'âge cohérents
- **Prix de transfert** : Catégorisation en 4 groupes (Free, Cheap, Medium, Expensive)
- **Région géographique** : Regroupement en 5 grandes régions

1.2.3 Classification préalable : clustering K-Means

Une classification K-Means en **10 clusters** a été appliquée aux équipes pour réduire la dimensionnalité de la variable `team_name` (qui comportait initialement plusieurs centaines de modalités). Cette classification repose sur les caractéristiques des joueurs recrutés par chaque équipe (position, âge, région, prix ...). La variable `cluster` ainsi créée sera utilisée comme variable supplémentaire dans l'ACM pour caractériser les profils d'équipes.

Distribution des clusters :

- Cluster 0 : 4 284 acquisitions (23,9%)
- Cluster 3 : 2 472 acquisitions (13,8%)
- Cluster 6 : 2 111 acquisitions (11,8%)
- Autres clusters : proportions entre 9,8% et 10,3%

Projection des clusters : Le K-Means a permis de regrouper les équipes en dix clusters homogènes, mais cette partition purement algorithmique ne fournit pas, en elle-même, de critères interprétatifs clairs. Pour donner du sens à ces groupes, nous adoptons une approche fondée sur la projection de la variable cluster comme variable qualitative supplémentaire sur le plan factoriel de l'ACM. Cette projection s'appuie sur des axes déjà interprétés et met en évidence les profils stratégiques propres à chaque cluster : politiques de transfert, tranches d'âge ciblées, ligues d'origine et postes privilégiés.

Ainsi, la combinaison du K-Means, qui assure la structuration des données, et de l'ACM, qui en permet l'interprétation, transforme des regroupements numériques en profils stratégiques cohérents et directement exploitables.

2 Application de l'Analyse des Correspondances Multiples

Les justifications du choix de l'Analyse des Correspondances Multiples (ACM) sont présentées dans la section ci-dessous et en annexe A.

2.1 Définition du modèle

L'ACM a été appliquée sur les 6 variables actives sélectionnées. Le Tableau Disjonctif Complet (TDC) résultant comporte 17 962 lignes (individus) et 24 colonnes (modalités).

Paramètres du modèle :

- Nombre de variables actives : 6
- Nombre de modalités : 24
- Nombre d'axes factoriels : 18 (égal à $K - p = 24 - 6$, où K est le nombre de modalités et p le nombre de variables)
- Inertie totale théorique : $\frac{K-p}{p} = \frac{19}{6} = 3,000$
- Seuil Kaiser : $\bar{\lambda} = \frac{1}{p} = \frac{1}{6} \approx 0,167$

2.2 Valeurs propres et inertie expliquée

2.2.1 Tableau des valeurs propres

Le tableau ci-dessous présente les valeurs propres brutes (issues de la diagonalisation) ainsi que les valeurs corrigées par la méthode de Benzécri pour les 5 premiers axes factoriels.

TABLE 1 – Valeurs propres et inertie expliquée (brute et corrigée)

Axe	λ brute	Inertie %	Cumul %	λ Benzécri	Inertie Benz. %
1	0,2535	8,45	8,45	0,0109	57,04
2	0,2249	7,50	15,95	0,0049	25,67
3	0,2030	6,77	22,71	0,0019	9,98
4	0,1886	6,29	29,00	0,0007	3,64
5	0,1835	6,12	35,12	0,0004	2,15

Note méthodologique : La correction de Benzécri ajuste les valeurs propres pour tenir compte de l'effet de dilution dû au grand nombre de modalités. Elle est définie par la formule (1.8) :

$$\lambda_{Benzécri} = \left[\frac{p}{p-1} \left(\lambda_{brute} - \frac{1}{p} \right) \right]^2$$

Cette correction s'applique uniquement aux valeurs propres supérieures au seuil Kaiser $\bar{\lambda} = \frac{1}{p}$. Elle affecte uniquement l'interprétation de l'inertie (pourcentages expliqués) mais ne modifie pas la géométrie des axes ni les coordonnées des individus et modalités.

2.2.2 Comparaison avant/après correction de Benzécri

Le tableau ci-dessous résume l'impact de la correction de Benzécri :

TABLE 2 – Impact de la correction de Benzécri

Mesure	Brute	Benzécri
Inertie Axe 1	8,45%	57,04%
Inertie Axe 2	7,50%	25,67%
Inertie cumulée (Axes 1+2)	15,95%	82,72%

2.2.3 Visualisation de l'éboulis des valeurs propres




FIGURE 1 – Éboulis des valeurs propres (brutes et corrigées)

Interprétation : Les deux premiers axes se détachent nettement au-dessus du seuil Kaiser ($\bar{\lambda} = 0,167$). La décroissance rapide des valeurs propres suivantes confirme que ces deux dimensions concentrent l'essentiel de la structure informationnelle du marché.

2.2.4 Inertie cumulée




FIGURE 2 – Pourcentage d'inertie cumulée (brute vs Benzécri)

Synthèse des résultats d'inertie :

TABLE 3 – Synthèse comparative des inerties

Critère	Inertie brute	Inertie Benzécri
Axe 1 seul	8,45%	57,04%
Axes 1+2 cumulés	15,95%	82,72%
Axes 1+2+3 cumulés	22,71%	92,70%

2.3 Choix des axes retenus

Les axes retenus sont ceux dont la valeur propre dépasse le seuil Kaiser ($\bar{\lambda} = 0,167$). Selon ce critère, **8 axes** sont significatifs.

Justification du choix de 2 axes : Bien que 8 axes dépassent le seuil Kaiser, les deux premiers axes capturent à eux seuls **82,72% de l'inertie corrigée (Benzécri)**, ce qui représente une qualité de représentation excellente. Ce pourcentage très élevé indique que ces deux dimensions synthétisent efficacement la quasi-totalité de l'information structurante du marché des transferts. L'ajout d'axes supplémentaires n'apporterait qu'une faible amélioration (17,28% restants répartis sur 6 axes) au prix d'une complexité d'interprétation nettement accrue.

2.4 Projection des individus




FIGURE 3 – Nuage des individus sur le plan factoriel (Axes 1 et 2)

Interprétation : La projection sur le plan factoriel montre une dispersion des transferts reflétant l'hétérogénéité du marché. Les points se structurent progressivement, illustrant la diversité continue des profils et leur position relative par rapport aux tendances dominantes.

2.5 Contributions et qualité de représentation des modalités

2.5.1 Projection des modalités actives

Les modalités actives sont projetées sur le plan factoriel principal. Deux visualisations complémentaires sont proposées pour évaluer leur importance :




FIGURE 4 – Visualisations complémentaires des modalités actives

2.5.2 Contributions des modalités par axe

Les contributions des modalités permettent d'interpréter le sens des axes factoriels.




FIGURE 5 – Contributions des modalités aux axes factoriels

Interprétation :

- **Axe 1** : Cet axe est dominé par `is_free__True` (20,80%) et `Young <=21` (16,50%), et structure le marché selon une logique économique et générationnelle. Sur cet axe, les jeunes joueurs (`Young <=21`) et les acquisitions payantes (`is_free__False`) se situent du côté négatif, tandis que les transferts gratuits (`is_free__True`) et les joueurs vétérans (`Veteran 30+` : 8,85%) se positionnent du côté positif. Cette dimension met en évidence l'opposition entre investissements sur jeunes talents et transferts gratuits de joueurs expérimentés en fin de carrière.
- **Axe 2** : Structuré principalement par les spécificités de poste (`Goalkeeper` : 14,51%) et l'origine géographique (`South America` : 11,32%, `Africa` : 9,24%), cet axe oppose les gardiens et joueurs issus d'Amérique du Sud ou d'Afrique aux autres positions et origines européennes respectivement. Bien que la variable `league` affiche une contribution cumulée de 20,70%, elle n'est pas retenue comme contributeur principal ; la justification détaillée de ce choix méthodologique est présentée dans la section 2.5.4 (Contributions des variables), où l'on examine également la qualité de représentation moyenne par variable (voir Figure D.2 en annexe).

2.5.3 Qualité de représentation ($\cos^2$) des modalités




FIGURE 6 – Qualité de représentation des modalités

Interprétation : Cette analyse de la qualité de représentation permet de valider que les modalités identifiées comme contributeurs majeurs lors de l'analyse précédente possèdent effectivement une bonne qualité de projection. Sur l'axe 1, nous retrouvons **is_free__True**, **age_group__Young** et **league__P01** avec des $\cos^2$ (43,4%, 40,4%, 23,1%), confirmant que leur forte contribution s'accompagne d'une représentation fidèle. De même, l'axe 2 capte fidèlement **player_pos_grouped__Goalkeeper** ($\cos^2 = 21,8\%$) et les régions **South America** et **Western Europe** ($\cos^2 = 17,7\%$, $\cos^2 = 30\%$).

Cette cohérence entre contribution et qualité de représentation est essentielle : une modalité peut contribuer fortement à un axe tout en étant mal représentée si sa variabilité est également expliquée par d'autres dimensions. Inversement, certaines modalités présentent une bonne qualité de représentation ($\cos^2 > 40\%$) sans être les contributeurs principaux, comme **is_free__False** sur l'axe 1, indiquant qu'elle est bien positionnée sur le plan factoriel mais avec une inertie plus faible. L'analyse conjointe de ces deux critères (contribution et $\cos^2$) garantit la robustesse de l'interprétation des axes factoriels.

2.5.4 Contributions des variables

Pour une vue globale, les contributions sont agrégées par variable :




FIGURE 7 – Contributions des variables actives aux axes

Interprétation : L'axe 1 est structuré par **age_group** (31,36%), **is_free** (28,56%), confirmant sa nature économico-générationnelle. L'axe 2 est dominé par **player_region** (32,65%) et **player_pos_grouped** (19,63%), deux variables présentant des oppositions claires et interprétables. Bien que **league** affiche une contribution de 20,70% sur l'axe 2, cette variable n'est pas retenue comme contributeur principal sur l'axe 2 pour deux raisons complémentaires (les mêmes raisons pour la même variable "League" sur l'axe 1) :

(1) **Dispersion de la contribution :** La contribution de 20,70% se fragmente entre sept modalités de ligues (IT1, P01, FR1, NL1, GB1, ES1, L1) sans qu'aucune ne se démarque fortement. Aucune modalité individuelle ne dépasse 9,89% de contribution, contrairement à **Goalkeeper** (14,51%) ou **South America** (11,32%) qui structurent clairement l'axe.

(2) **Faible qualité de représentation :** Le $\cos^2$ moyen de **league** sur l'axe 2 est de seulement 4,7%, indiquant que cette variable est mal représentée sur cette dimension (aussi sur l'axe 1 où son $\cos^2$ atteint 5,9%). À l'inverse, **player_region** ($\cos^2 : 13,3\%$) et **player_pos_grouped** ($\cos^2 : 7,9\%$) sont substantiellement mieux représentés sur l'axe 2, validant leur rôle structurant.

L'interprétation de l'axe 2 privilégie donc les variables offrant à la fois des contrastes nets entre modalités et une bonne qualité de représentation, soit `player_region` et `player_pos_grouped`.

2.6 Dénomination des axes

Sur la base des contributions et des modalités structurantes, les axes se définissent comme suit :

- **Axe 1 – Dimension économique et générationnelle** : Cet axe oppose les transferts gratuits (`is_free__True`) aux jeunes joueurs (`age_group__Young` ≤ 21 ans) et place les vétérans (≥ 30 ans) à l'autre extrémité. Il illustre la tension entre opportunités de marché (joueurs libres) et investissements sur jeunes talents à fort potentiel.
- **Axe 2 – Dimension positionnelle et géographique** : Cet axe capture les spécialisations de recrutement selon deux critères indépendants du budget. D'une part, la singularité du poste de gardien de but, dont les caractéristiques techniques et le marché diffèrent substantiellement des autres positions. D'autre part, l'importance des bassins de recrutement sud-américain et africain, viviers privilégiés pour certains clubs ayant développé des réseaux de détection spécifiques. Cette dimension traduit les logiques de recrutement par niches tactiques et géographiques.

2.7 Synthèse des regroupements de modalités

L'analyse conjointe des figures 4a (qualité de représentation) et 4b (contribution) révèle plusieurs regroupements spatiaux de modalités bien représentées sur le plan factoriel :

TABLE 4 – Regroupements de modalités sur le plan factoriel

Groupe	Modalités regroupées	Qualité représentation	Interprétation
Groupe 1 Transferts gratuits de vétérans (côté positif axe 1)	<code>is_free__True</code> (+) <code>Veteran 30+</code> (+)	Excellente sur axe 1	Joueurs expérimentés en fin de contrat recrutés gratuitement, opportunités de marché sans investissement.
Groupe 2 Jeunes joueurs à transfert payant (côté négatif axe 1)	<code>age_group__Young</code> (-) <code>is_free__False</code> (-)	Bonne sur axe 1	Investissements financiers sur jeunes talents à développer, stratégie de valorisation future.
Groupe 3 Recrutement Sud-Amérique/Afrique dans la ligue P01 (côté négatif axe 2)	<code>player_region__South America</code> (-) <code>player_region__Africa</code> (-) P01 (-)	Excellente sur axe 2	La ligue P01 forme un réseau de détection spécialisés dans bassins sud-américain et africain.
Groupe 4 Profil standard central (proximité origine)	<code>age_group__Experienced</code> (neutre axe 1) <code>age_group__Prime</code> (représenté axe 2)	Modérée, positionnement central	Majorité des acquisitions standard, joueurs en phase de maturité sportive sans caractéristique extrême.

Synthèse : Le plan factoriel structure le marché en 4 profils distincts basés sur deux logiques : (2) gratuité/jeunesse sur l'axe 1, et (1) spécialisation géographique sur l'axe 2. Les modalités à forte qualité de représentation définissent clairement ces pôles structurants du marché des transferts.

3 Projection de variables supplémentaires

3.1 Méthode de projection

L'Analyse des Correspondances Multiples (ACM) a été réalisée sur les variables actives qualitatives. Les variables supplémentaires sont projetées a posteriori sans contribuer à la construction des axes factoriels.

Méthode de projection :

- **Variables qualitatives supplémentaires** : Projetées comme barycentres des coordonnées factorielles individuelles. Pour chaque modalité k d'une variable qualitative, les coordonnées sont calculées comme la moyenne des coordonnées des individus appartenant à cette modalité.
- **Variables quantitatives supplémentaires** : Projetées par corrélation de Pearson entre la variable standardisée et les coordonnées individuelles sur les axes factoriels.

Ces projections sont purement descriptives et permettent d'enrichir l'interprétation sans modifier la structure factorielle.

3.2 Projection de la valeur marchande et des catégories de prix




FIGURE 8 – Projection des variables supplémentaires sur le plan factoriel

3.2.1 Variable quantitative : `market_val_amnt`

La variable `market_val_amnt` (valeur marchande) est représentée par un vecteur bleu dont la longueur et la direction indiquent la corrélation avec les axes :

- **Corrélation avec l'axe 1** : $r = -0,192$, corrélation négative faible à moyenne
- **Corrélation avec l'axe 2** : $r = -0,063$, corrélation négative très faible

Conclusion : La corrélation négative faible à moyenne avec l'axe 1 ($r = -0,192$) suggère que les joueurs situés du côté positif de l'axe — correspondant aux transferts gratuits — tendent à avoir des valeurs marchandes légèrement inférieures. Cette tendance reste modeste et n'est pas déterministe, rappelant que l'axe 1 ne capture qu'une part limitée de la variation économique. L'absence de corrélation avec l'axe 2 ($r = -0,063$) indique que la valeur marchande n'est pas structurée par les contrastes positionnels ou géographiques représentés par cet axe : un gardien ou un joueur sud-américain peut être valorisé autant qu'un gardien ou un joueur européen selon ses qualités propres.

3.2.2 Variable qualitative : `transfer_fee_group`

Les barycentres des modalités de `transfer_fee_group` (catégories de prix) sont représentés par des points rouges. D'après la visualisation de la figure 8, on observe :

- **Free** : Position positive sur l'axe 1, cohérente avec la modalité `is_free__True`
- **Cheap (0-2M)** : Position intermédiaire, proche de l'origine
- **Medium (2-7M)** : Position légèrement négative sur l'axe 1
- **Expensive (7M+)** : Position nettement négative sur l'axe 1

Interprétation : Les modalités de prix dessinent un continuum économique ordonné sur l'axe 1 : **Free** (extrémité positive) → **Cheap** (position centrale) → **Medium** (légèrement négative) → **Expensive** (extrémité négative). Cette progression linéaire valide l'interprétation économique de l'axe 1 et démontre que le prix de transfert reflète le positionnement stratégique des acquisitions. L'absence de dispersion sur l'axe 2 confirme que la dimension tarifaire est orthogonale aux spécificités positionnelles et géographiques.

3.3 Analyse ciblée : comportement des transferts non gratuits

L'axe 1 est dominé par la modalité `is_free`. Une question naturelle se pose : **Comment se comportent les transferts non gratuits (`is_free=False`) ?**

Pour répondre à cette question, nous examinons la projection de la variable `transfer_fee_group` :

Observations :

- Les transferts **Cheap (0-2M)** sont proches de l'origine sur l'axe 1, suggérant un profil intermédiaire entre gratuit et payant.
- Les transferts **Medium (2-7M)** occupent une position légèrement négative sur l'axe 1, caractérisant un marché moyen. Ces acquisitions correspondent typiquement à des joueurs en phase Prime (22-25 ans) ou Experienced (26-29 ans) dans des ligues intermédiaires.
- Les transferts **Expensive (7M+)** se situent nettement à l'opposé des transferts gratuits sur l'axe 1 et sont associés à de jeunes joueurs à fort potentiel, dans lesquels les clubs des grandes ligues européennes (L1, GB1) investissent.

Conclusion : La projection de `transfer_fee_group` dépasse la dichotomie gratuit/payant en révélant une stratification fine du marché. Le continuum **Cheap** → **Medium** → **Expensive** traduit l'ajustement des prix aux caractéristiques des joueurs (âge, expérience). Cette gradation confirme que le marché fonctionne selon une logique d'évaluation, où le montant investi corrèle avec le profil acquis. Les clubs disposent ainsi d'un spectre large de stratégies, de l'opportunisme *low-cost* à l'investissement premium ciblé.

4 Projection de la variable `cluster` (Classification K-Means)

La variable `cluster` résulte d'une classification K-Means appliquée aux équipes pour regrouper les entités ayant des profils d'acquisition similaires.

4.1 Projection des clusters sur le plan factoriel




FIGURE 9 – Projection de la variable `cluster` sur le plan factoriel ACM

4.1.1 Caractérisation des clusters

Les barycentres des 10 clusters sont projetés sur le plan factoriel. Leur position relative révèle les profils d'acquisition :

- **Clusters positionnés positivement sur l'axe 1 :** Ces clusters correspondent à des équipes recrutant principalement des agents libres et de joueurs vétérans, adoptant une stratégie *low-cost* typique des équipes de ligues mineures ou d'équipes en reconstruction.
- **Clusters positionnés négativement sur l'axe 1 :** Ces clusters regroupent des équipes investissant dans des transferts payants de jeunes joueurs, caractéristiques des grandes équipes européennes (top ligues -GB1,FR1-) avec des budgets conséquents .

- **Clusters centraux** : Position proche de l'origine, représentant des équipes avec une stratégie mixte, équilibrant transferts gratuits et payants selon les opportunités du marché.
- **Dispersion sur l'axe 2** : Certains clusters se distinguent sur l'axe 2, révélant des spécialisations de recrutement par position (ex : équipes recrutant davantage d'attaquants) ou par origine géographique (ex : focus sur Amérique du Sud ou Afrique).

4.2 Pertinence de la classification

La projection des clusters sur le plan ACM valide la pertinence de la classification K-Means :

- **Séparation spatiale** : Les clusters présentent une bonne séparation avec des barycentres distincts, confirmant qu'ils capturent des stratégies de recrutement réellement différenciées.
- **Alignement avec les axes factoriels** : Les clusters s'alignent principalement selon l'axe 1 (dimension économique : gratuit vs payant), confirmant que cette dimension structure fortement le marché. L'axe 2 apporte une nuance secondaire liée aux spécialisations positionnelles et géographiques.

Conclusion : La classification K-Means capture efficacement les profils stratégiques d'équipes. L'ACM révèle que ces profils sont structurés principalement par la dimension économique et d'âge (axe 1) et, secondairement, par les spécialisations de recrutement (axe 2).

5 Synthèse & perspectives

5.1 Principaux profils identifiés

L'ACM a permis d'identifier plusieurs profils-types d'acquisitions sur le marché européen des transferts :

1. Profil "Opportunité low-cost".
2. Profil "Investissement stratégique premium".
3. Profil "Spécialisation géographique".
4. Profil "Marché moyen équilibré".

Convergence entre profils de modalités et clusters d'équipes : L'analyse révèle une cohérence remarquable entre les regroupements de modalités identifiés sur le plan factoriel (section 2.7) et les clusters d'équipes issus de la classification K-Means (section 4.1.1). Les quatre groupes de modalités — transferts gratuits de vétérans, jeunes joueurs à transfert payant, recrutement géographique spécialisé, et profil standard central — correspondent directement aux profils stratégiques des clusters d'équipes. Cette convergence valide la double structuration du marché : au niveau des transactions individuelles (modalités) et au niveau des stratégies collectives d'équipes (clusters), confirmant que les équipes adoptent des politiques de recrutement cohérentes alignées sur les dimensions économiques, générationnelles et géographiques du marché.

5.2 Contributions méthodologiques

Cette étude illustre l'apport de l'ACM pour l'analyse de marchés complexes :

- **Identification d'associations non linéaires** : Contrairement à l'ACP, l'ACM révèle des associations entre modalités qualitatives sans présupposer de relations linéaires.
- **Correction de Benzécri** : Améliore l'interprétation de l'inertie en tenant compte de la structure du TDC.
- **Projection de variables supplémentaires** : Enrichit l'interprétation sans biaiser la construction des axes.
- **Couplage K-Means et ACM** : La combinaison de la classification K-Means pour le prétraitement (réduction de dimensionnalité) et de l'ACM pour l'interprétation permet de transformer des regroupements algorithmiques en profils stratégiques interprétables. La projection des clusters sur le plan factoriel révèle et valide les logiques de recrutement des équipes.

5.3 Limites et perspectives

5.3.1 Limites

- **Qualité de représentation des individus limitée** : Le nombre élevé de modalités entraîne une dispersion de l'inertie, réduisant la qualité de représentation des individus sur les premiers axes.

Seules les modalités bénéficient d'une bonne représentation, ce qui est caractéristique de l'ACM en haute dimensionnalité.

- **Temporalité difficilement exploitable** : L'inclusion de la variable `season` comme variable active a été testée mais n'a pas produit de résultats interprétables. Sa forte contribution écrasait les autres dimensions structurantes des axes factoriels tout en présentant une faible qualité de représentation, masquant ainsi les associations économiques et stratégiques plus pertinentes pour l'analyse du marché.
- **Imputation par apprentissage automatique** : Les valeurs manquantes de deux variables quantitatives ont été imputées par apprentissage automatique, ce qui introduit une approximation éloignant légèrement les analyses de la réalité empirique.

5.3.2 Perspectives

1. **Enrichissement des variables** : Intégrer des variables supplémentaires (performance des joueurs, durée de contrat, etc.) pour affiner les profils.
2. **Enrichissement des données manquantes** : Collecter les valeurs réelles pour remplacer les données imputées et améliorer la fiabilité des analyses.
3. **Extension au troisième axe factoriel** : Intégrer l'axe 3 dans l'analyse pour améliorer la qualité de représentation des modalités et capturer des dimensions complémentaires non exploitées par les deux premiers axes.

5.4 Recommandations analytiques

Pour les analystes de données sportives et les décideurs du marché des transferts :

- **Cibler les profils atypiques** : Les individus excentrés sur le plan factoriel représentent des opportunités ou des risques (joueurs sous-évalués).
- **Adapter les stratégies de recrutement** : Les clusters d'équipes révèlent des stratégies distinctes (low-cost, investissement stratégique, etc.) qui peuvent inspirer des décisions de recrutement.
- **Optimiser les ventes de joueurs** : Les équipes souhaitant vendre un joueur devraient cibler les clusters d'équipes correspondant au profil du joueur (âge, position, région d'origine) pour maximiser les chances de transaction en proposant le joueur aux acheteurs potentiels partageant une stratégie de recrutement cohérente avec ce profil.

Conclusion

L'Analyse des Correspondances Multiples appliquée à 17 962 acquisitions de joueurs sur le marché européen des transferts a permis d'identifier les principales structures du marché. Les deux premiers axes factoriels capturent 82,72% de l'inertie corrigée (Benzécri) et révèlent des oppositions claires :

- **Axe 1 (57,04% Benzécri)** : Profil économique et d'âge — Transferts gratuits de joueurs vétérans (+30 ans) dans ligues mineures vs transferts payants de jeunes joueurs dans grandes ligues
- **Axe 2 (25,67% Benzécri)** : Spécialisation positionnelle et géographique — Gardiens ou joueurs d'Amérique du Sud/Afrique vs autres positions et origines européennes

La projection de variables supplémentaires (valeur marchande, catégories de prix, clusters d'équipes) enrichit l'interprétation et confirme la pertinence des axes. Les clusters d'équipes, issus d'une classification K-Means, sont bien distincts sur le plan factoriel et reflètent des stratégies de recrutement cohérentes.

Au-delà des résultats spécifiques, cette étude illustre comment l'ACM permet de révéler des structures latentes et des tendances implicites dans des données qualitatives complexes, offrant une perspective stratégique pour interpréter et comprendre les structures sous-jacentes du phénomène observé.

A Comparaison méthodologique (ACM / ACP / FAMD)

A.1 Analyse en Composantes Principales (ACP)

Principe : L'ACP est une méthode d'analyse factorielle adaptée aux variables quantitatives continues. Elle repose sur la diagonalisation de la matrice de covariance (ou corrélation) pour identifier les directions de variance maximale.

Avantages :

- Interprétation directe en termes de variance expliquée
- Efficace pour des variables continues corrélées

Limites :

- Ne s'applique pas directement aux variables qualitatives
- Suppose des relations linéaires entre variables

Pourquoi l'ACP n'a pas été retenue : Notre jeu de données est majoritairement qualitatif (11/13 variables), rendant l'ACP inadaptée.

A.2 Analyse Factorielle de Données Mixtes (FAMD)

Principe : La FAMD combine ACP (pour les variables quantitatives) et ACM (pour les variables qualitatives) dans une analyse unifiée.

Avantages :

- Traite simultanément variables quantitatives et qualitatives
- Pondération automatique pour équilibrer les contributions

Limites :

- Interprétation plus complexe (deux types de contributions)
- Efficacité réduite si un type de variable est minoritaire

Pourquoi la FAMD n'a pas été retenue : Avec seulement 2 variables quantitatives contre 11 qualitatives, la FAMD aurait donné un poids excessif aux variables quantitatives. L'ACM, en se concentrant sur les variables qualitatives, offre une meilleure lisibilité.

A.3 Analyse des Correspondances Multiples (ACM)

Principe : L'ACM est une généralisation de l'Analyse des Correspondances (AFC) aux tableaux à plus de deux variables qualitatives. Elle repose sur le Tableau Disjonctif Complet (TDC) et identifie les associations entre modalités.

Avantages :

- Adaptée aux variables qualitatives nominales
- Révèle des associations non linéaires
- Permet la projection de variables supplémentaires a posteriori

Limites :

- Inertie brute relativement faible (due à la structure du TDC)
- Sensible aux modalités rares (nécessite un prétraitement)

Pourquoi l'ACM a été retenue : L'ACM est la méthode la plus adaptée à notre jeu de données qualitatif. La correction de Benzécri compense la faiblesse de l'inertie brute, et la projection a posteriori permet d'intégrer les variables quantitatives sans biaiser l'analyse.

B Preprocessing détaillé

B.1 Imputation des valeurs manquantes

Les valeurs manquantes ont été traitées selon les règles suivantes :

- **Variables qualitatives :** Remplacement par la modalité "Manquant" ou "Unknown"
- **Variables quantitatives :** Imputation par la médiane (méthode robuste aux outliers)

Justification : Cette approche conserve l'information sur l'absence de données sans introduire de biais significatif.

B.2 Regroupement des modalités rares

Les modalités représentant moins de 1% des observations ont été regroupées dans une catégorie "Autre" ou fusionnées avec des modalités voisines.

Exemples :

- `player_nation` : 153 modalités → regroupement en `player_region` (5 modalités)
- `team_name` : Plusieurs centaines de modalités → clustering K-Means en 10 clusters

B.3 Clustering K-Means des équipes

Objectif : Réduire la variable `team_name` (trop de modalités) en une variable `cluster` (10 modalités).

Méthode :

1. Agrégation des caractéristiques des joueurs par équipe (moyenne d'âge, répartition des positions, prix moyen, etc.)
2. Application de K-Means avec $k = 10$ (choix basé sur la méthode du coude et l'analyse des silhouettes)
3. Attribution d'un label de cluster à chaque acquisition

Résultat : 10 clusters d'équipes reflétant des stratégies de recrutement distinctes.

C Pipeline détaillé de prétraitement des données

Cette annexe présente le processus complet de prétraitement appliqué aux données brutes de transferts de joueurs, depuis le jeu de données initial de 70 006 observations jusqu'au jeu de données final de 17 962 acquisitions utilisé pour l'analyse ACM.

A.1. Vue d'ensemble du pipeline

Le prétraitement s'articule en 15 étapes séquentielles, chacune visant à améliorer la qualité et la cohérence des données :

TABLE 5 – Résumé des étapes de prétraitement

Étape	Opération	Observations	Variables
0	Données brutes initiales	70 006	23
1-2	Import et chargement	70 006	23
3	Suppression événements non-transferts	56 336	21
4	Filtrage transferts extrêmes	56 330	21
5	Suppression identifiants	56 330	15
6	Filtrage transferts permanents	36 587	14
7	Filtrage transferts entrants	18 003	13
8	Gestion valeurs manquantes	17 982	13
9	Création groupes de position	17 982	14
10	Création régions géographiques	17 982	15
11	Création groupes d'âge	17 982	15
12	Prédiction valeurs manquantes	17 982	15
13	Catégorisation montants transfert	17 982	16
14	Classification K-Means équipes	17 982	17
15	Dataset final	17 962	13

Note : La différence finale de 20 observations ($17\,982 \rightarrow 17\,962$) résulte de la sélection finale des variables et du nettoyage des incohérences résiduelles.

A.2. Description détaillée des étapes

Étape 1-2 : Import des bibliothèques et chargement des données

Objectif : Initialiser l'environnement d'analyse et charger le jeu de données brut.

Opérations :

- Import des bibliothèques : `pandas`, `numpy`, gestion des warnings
- Fixation de la graine aléatoire (`seed=42`) pour reproductibilité
- Chargement du fichier `raw_transfers.csv` (70 006 lignes, 23 colonnes)

Variables initiales : `league`, `season`, `window`, `team_id`, `team_name`, `team_country`, `dir`, `player_id`, `player_name`, `player_age`, `player_nation`, `player_nation2`, `player_pos`, `counter_team_id`, `counter_team_name`, `counter_team_country`, `transfer_fee_amnt`, `market_val_amnt`, `is_free`, `is_loan`, `is_loan_end`, `is_retired`, `transfer_id`.

Étape 3 : Suppression des événements non-transferts

Objectif : Éliminer les fins de prêt et les retraits qui ne constituent pas des transferts réels.

Critères de filtrage :

- `is_loan_end == True` : Fins de contrat de prêt
- `is_retired == True` : Départs en retraite

Résultats :

- Observations supprimées : 13 670 (19,5%)
- Observations conservées : 56 336
- Variables supprimées : `is_loan_end`, `is_retired` (2 colonnes)

Justification : Les fins de prêt et retraits ne reflètent pas des décisions d'acquisition stratégiques et introduiraient un biais dans l'analyse du marché des transferts.

Étape 4 : Filtrage des montants de transfert extrêmes

Objectif : Supprimer les valeurs aberrantes irréalistes.

Critère : Montant de transfert > 250 000 000€

Résultats :

- Observations supprimées : 6 (0,01%)
- Observations conservées : 56 330
- Montant maximum après filtrage : 222 000 000€

Justification : Les transferts supérieurs à 250M€ sont considérés comme des erreurs de saisie, le record historique réel étant de 222M€ (Neymar, 2017).

Étape 5 : Suppression des variables d'identification

Objectif : Retirer les identifiants uniques non pertinents pour l'analyse.

Variables supprimées (6) :

- `team_id`, `player_id`, `counter_team_id`, `transfer_id` : Identifiants numériques
- `player_name` : Nom du joueur (non utilisé en ACM)
- `player_nation2` : Deuxième nationalité (66,9% de valeurs manquantes)

Résultats :

- Variables conservées : 15

Étape 6 : Filtrage des transferts permanents

Objectif : Conserver uniquement les acquisitions définitives.

Critère : `is_loan == False`

Résultats :

- Observations supprimées (prêts) : 19 743 (35,1%)
- Observations conservées : 36 587

Justification : Les prêts obéissent à une logique économique différente (absence de transfert de propriété) et ne reflètent pas les investissements stratégiques des clubs.

Étape 7 : Filtrage des transferts entrants

Objectif : Focaliser l'analyse sur les stratégies d'acquisition.

Critère : `dir == 'in'` (direction entrante uniquement)

Résultats :

- Observations supprimées (sorties) : 18 584 (50,8%)
- Observations conservées : 18 003

Justification : L'étude se concentre sur les politiques de recrutement (achats de joueurs) plutôt que sur les stratégies de vente, qui répondent à des contraintes différentes.

Étape 8 : Gestion des valeurs manquantes critiques

Objectif : Éliminer les observations incomplètes pour les variables essentielles.

Critères de suppression :

- `player_age` manquant : 16 observations (0,09%)
- `player_nation` manquant : 5 observations (0,03%)

Valeurs manquantes conservées :

- `transfer_fee_amnt` : 10 739 (59,7%) — Sera imputée à l'étape 12
- `market_val_amnt` : 4 946 (27,5%) — Sera imputée à l'étape 12

Résultats :

- Observations conservées : 17 982

Justification : L'âge et la nationalité sont des variables fondamentales pour l'analyse. Les valeurs manquantes des montants financiers, fréquentes pour les transferts non divulgués, sont conservées pour imputation ultérieure par apprentissage automatique.

Étape 9 : Création des groupes de position

Objectif : Réduire la dimensionnalité de la variable `player_pos` (16 modalités).

Regroupement appliqué :

Groupe créé	Positions d'origine
Goalkeeper	GK
Defender	CB, LB, RB, defence
Midfielder	DM, CM, AM, LM, RM, midfield
Forward	LW, RW, CF, SS, attack

Distribution résultante :

- Midfielder : 6 867 (38,2%)
- Defender : 6 353 (35,3%)
- Forward : 3 293 (18,3%)
- Goalkeeper : 1 469 (8,2%)

Variable créée : `player_pos_grouped` (4 modalités)

Étape 10 : Création des régions géographiques

Objectif : Regrouper 168 nationalités en 5 zones géographiques cohérentes.

Régions définies :

- **Western Europe** (24 pays) : Angleterre, France, Allemagne, Italie, Espagne, Pays-Bas, Belgique, Portugal, etc.
- **Eastern Europe** (26 pays) : Pologne, République Tchèque, Russie, Ukraine, Croatie, Serbie, Grèce, Turquie, etc.
- **South America** (13 pays) : Brésil, Argentine, Uruguay, Colombie, Chili, Paraguay, etc.
- **Africa** (38 pays) : Sénégal, Ghana, Nigeria, Côte d'Ivoire, Cameroun, Maroc, etc.
- **Other** : Nationalités non classées dans les catégories précédentes

Distribution résultante :

- Western Europe : 9 287 (51,6%)
- South America : 2 765 (15,4%)
- Eastern Europe : 2 476 (13,8%)
- Africa : 2 189 (12,2%)
- Other : 1 265 (7,0%)

Variable créée : `player_region` (5 modalités)

Étape 11 : Création des groupes d'âge

Objectif : Discrétiser l'âge en catégories correspondant aux phases de carrière.

Découpage appliqué :

Groupe	Intervalle	Phase de carrière
Young (≤ 21)	[0, 21]	Jeunes talents en développement
Prime (22-25)	]21, 27]	Joueurs en pleine maturité
Experienced (26-29)	]27, 31]	Joueurs expérimentés
Veteran (30+)	]31, ∞ [	Vétérans en fin de carrière

Distribution résultante :

- Young (≤ 21) : 4 883 (27,2%)
- Prime (22-25) : 5 127 (28,5%)
- Experienced (26-29) : 4 396 (24,4%)
- Veteran (30+) : 3 576 (19,9%)

Variable créée : `age_group` (4 modalités)

Note : La variable `player_age` (quantitative) est supprimée après création de `age_group`, l'ACM nécessitant des variables qualitatives.

Étape 12 : Prédiction des valeurs manquantes par apprentissage automatique

Objectif : Imputer les valeurs manquantes de `market_val_amnt` et `transfer_fee_amnt`.

Méthodologie :

- **Modèles testés :** Linear Regression, Ridge, Random Forest, **Gradient Boosting Regressor** (retenu)
- **Variables prédictives :** `player_age`, `player_pos`, `league`, `season`, `window`, `player_region`
- **Prétraitement :** StandardScaler (variables numériques) + OneHotEncoder (variables catégorielles)
- **Validation :** Cross-validation (5 folds), métriques MAE, RMSE, R^2

Ajustements spécifiques :

- **Ligues NL1 et PO1 :** Application d'un coefficient multiplicateur de 0,75 aux valeurs prédites pour tenir compte des spécificités économiques de ces marchés (valeurs marchandes et montants de transferts systématiquement plus faibles).

Résultats :

- Toutes les valeurs manquantes imputées avec succès
- Fichier de sortie : `transfers_with_imputed_values.csv`

Justification : L'imputation par apprentissage automatique préserve les corrélations entre variables et évite la perte d'observations. Le Gradient Boosting Regressor a démontré les meilleures performances en validation croisée.

Étape 13 : Catégorisation des montants de transfert

Objectif : Créer une variable qualitative de prix pour enrichir l'analyse.

Catégories définies :

Catégorie	Condition	Interprétation
Free	<code>fee = 0</code> ou <code>is_free = True</code>	Transferts gratuits
Cheap (0-2M)	$0 < \text{fee} \leq 2\,000\,000$	Acquisitions économiques
Medium (2-7M)	$2\,000\,000 < \text{fee} \leq 7\,000\,000$	Marché intermédiaire
Expensive (7M+)	<code>fee > 7\,000\,000</code>	Investissements majeurs
Unknown	<code>fee</code> manquant (avant imputation)	Montant non divulgué

Variable créée : `transfer_fee_group` (5 modalités)

Fichier de sortie : `frozen_dataset.csv`

Étape 14 : Classification K-Means des équipes

Objectif : Réduire la dimensionnalité de `team_name` (243 modalités) en regroupant les équipes par profils de recrutement.

Méthodologie :

- **Algorithme** : K-Means (sklearn)
- **Features agrégées par équipe** :
 - Numériques : Moyenne/médiane des valeurs marchandes, montants de transferts, nombre de transferts
 - Catégorielles : Distributions de positions, régions, groupes d'âge, catégories de prix, fenêtres de transfert, nationalités (top 15)
- **Normalisation** : StandardScaler
- **Sélection du nombre de clusters** : Optimisation par Silhouette Score (k testé de 3 à 10)
- **Nombre optimal retenu** : k = 10 clusters

Fichiers de sortie :

- `silhouette_scores.csv` : Scores d'évaluation pour chaque k
- `team_clusters.csv` : Affectation des équipes aux clusters
- `cluster_feature_means.csv` : Profils moyens des clusters
- `dataset_with_clusters.csv` : Dataset enrichi avec labels de clusters

Distribution des clusters :

- Cluster 0 : 4 284 acquisitions (23,9%)
- Clusters 1-9 : Entre 9,8% et 10,3% chacun

Variable créée : `cluster` (10 modalités)

Justification : La classification K-Means transforme une variable hautement dimensionnelle (`team_name`) en groupes homogènes interprétables, facilitant l'analyse ACM tout en préservant l'information stratégique des profils d'équipes.

Étape 15 : Sélection finale des variables et sauvegarde

Objectif : Constituer le dataset final pour l'analyse ACM.

Variables actives sélectionnées (6) :

1. `league` : Ligue européenne (7 modalités)
2. `window` : Fenêtre de transfert (2 modalités)
3. `player_pos_grouped` : Position regroupée (4 modalités)
4. `player_region` : Région géographique (5 modalités)
5. `age_group` : Groupe d'âge (4 modalités)
6. `is_free` : Transfert gratuit (2 modalités)

Variables supplémentaires conservées (5) :

- `market_val_amnt` : Valeur marchande (quantitative)
- `transfer_fee_amnt` : Montant du transfert (quantitative)
- `transfer_fee_group` : Catégorie de prix (qualitative, 5 modalités)
- `cluster` : Cluster d'équipe (qualitative, 10 modalités)
- `team_name`, `player_nation`, `season` : Variables de référence

Dataset final :

- Observations : 17 962
- Variables totales : 13 (6 actives + 7 supplémentaires/référence)
- Fichier de sortie : `analysis_ready_transfers.csv`

A.3. Synthèse des transformations

TABLE 6 – Bilan quantitatif du prétraitement

Indicateur	Avant	Après
Nombre d'observations	70 006	17 962
Taux de conservation	100%	25,7%
Nombre de variables	23	13
Variables qualitatives	11	11 (6 actives + 5 suppl.)
Variables quantitatives	3	2
Identifiants supprimés	—	6
Valeurs manquantes critiques	66,9% (<code>player_nation2</code>)	0% (imputées)

Justification du taux de conservation (25,7%) : Le filtrage sévère résulte de choix méthodologiques délibérés :

- **Exclusion des non-transferts** (-19,5%) : Fins de prêt et retraits
- **Focus transferts permanents** (-35,1%) : Exclusion des prêts
- **Focus transferts entrants** (-50,8%) : Analyse des stratégies d'acquisition uniquement

Ces choix garantissent la **cohérence thématique** de l'analyse en focalisant sur une population homogène : les acquisitions définitives de joueurs par les clubs européens.

Conclusion : Le pipeline de prétraitement transforme un jeu de données brut hétérogène en un dataset analytiquement exploitable, structuré autour de 6 variables actives qualitatives. Cette structuration rigoureuse constitue le fondement de la qualité de l'analyse ACM présentée dans le corps du rapport.

D Tableaux statistiques complets

D.1 Contributions détaillées des modalités

Note : Les tableaux complets des contributions et $\cos^2$ pour toutes les modalités et tous les axes sont disponibles dans le notebook source (`notebook.ipynb`).

D.2 Qualité de représentation moyenne par variable




FIGURE 10 – Qualité de représentation moyenne des variables actives par axe

Interprétation : Ces graphiques présentent la qualité de représentation moyenne ($\cos^2$) de chaque variable active sur les deux premiers axes factoriels. Sur l'axe 1, les variables `age_group`, `is_free` et `league` présentent les meilleurs $\cos^2$ moyens, confirmant qu'elles sont bien représentées sur cette dimension. Sur l'axe 2, `player_region` et `player_pos_grouped` dominent nettement, tandis que `league` affiche un $\cos^2$ très faible (4,7%), justifiant son exclusion de l'interprétation principale de cet axe malgré sa contribution cumulée élevée. Cette analyse valide les choix interprétatifs effectués dans les sections précédentes.